

Dynamic Conditional Correlation Models

I Background & Motivation

我们之前算的都是 single asset / portfolio 的 variance (GARCH)
这部分内容是关于为 comovement between asset 建模


为什么 correlation 这么重要呢？

像方差一样，correlation 也随时间变化，而 correlation 和 s.d. 一起决定了 covariance matrix，协方差矩阵对 mean-variance optimization 和 VaR 计算至关重要

下面我们来看一下 correlation 变化很大的案子：

* 10-year CMT yield 和
price 是反向的

- 这三张线变化都很大
Bond 和 Stock 一会
同向变化一会反向变化。
这个信息对我们很有
用：决定了我们应该
利用 Bond 来对冲 Stock
的 risk。



尽管一般的 assets 的 correlation 变化不会这么大

下面我們介紹一下 Background

先看一下 portfolio 的 return

$$r_{PF,t+1} = \sum_{i=1}^n w_{i,t} r_{i,t+1}$$

* r 是 simple return, 不是 compounded return

$$\delta_{PF,t+1}^2 = w_i' \sum_{i=1}^{n+1} w_i$$

2x2 case :

$$\delta_{PF,t+1}^2 = [w_{1,t}, w_{2,t}] \begin{bmatrix} \delta_{11,t+1} & \delta_{12,t+1} \\ \delta_{12,t+1} & \delta_{22,t+1} \end{bmatrix} \begin{bmatrix} w_{1,t} \\ w_{2,t} \end{bmatrix}$$

$$= w_{1,t}^2 \delta_{11,t+1} + w_{2,t}^2 \delta_{22,t+1} + 2w_{1,t} w_{2,t} \delta_{12,t+1}$$

在 $n \times n$ 的情況下有些難算, 解決這問題的一方法是

$$r_{PF,t+1} = r_{MKT,t+1} + \varepsilon_{t+1}$$

ε_{t+1} 是 idiosyncratic risk term, 即非市場 return

$$\text{那麼 } \delta_{PF,t+1}^2 = \delta_{MKT,t+1}^2 + \delta_{\varepsilon}^2$$

如果 portfolio is well-diversified, δ_{ε} will be very small, then

$$\delta_{PF,t+1}^2 = \delta_{MKT,t+1}^2$$

但是上面的模型太簡單了, 我們需要更复杂的模型

$$r_{PF,t+1} = \beta_1 r_{F1,t+1} + \varepsilon_{t+1}$$

↓更多的 factor

$$r_{PF,t+1} = \beta_1 r_{F1,t+1} + \dots + \beta_{10} r_{F10,t+1} + \varepsilon_{t+1}$$

美股有 4000 ~ 5000 支，算这么大的 correlation matrix 不现实。但是仍有 2000 支股票会被机构投资者买卖。但 2000 也是个很大的数字
这就是为什么我们用 Factor Model

II Introducing the DCC Model

DCC 是预测 correlation 的标准模型。就像 GARCH 是方差的标准模型


本部分要引入 DCC 模型

首先我们先讲一下以前我们是如何预测相关系数的呢？

Equally-weight estimator : $\sigma_{ij,t+1} = \frac{1}{m} \sum_{\tau=1}^m R_{i,t+1-\tau} R_{j,t+1-\tau}$

我们来看一下图：

有的时候 treasury note 和 stock 是不相关的 (uncorrelated)，有时却可以用 treasury note 来 hedge stock



这么做有什么坏处呢？

在 estimation window 中我们就有 weight。一旦 window 变大就是了一不平滑

另一种方法

Exponentially-weighted estimator $\sigma_{ij,t+1} = (1 - \lambda) R_{i,t} R_{j,t} + \lambda \sigma_{ij,t}$

在这丁图中极端值更极端一些，因为极端值被赋予了更高的权重



但是！ $1-\lambda + \lambda = 1$ 这不是
我们想要的，因为这样就没有

mean-reversion in covariance 了 为什么？

如果明天预测的 covariance 很高，它会一直都高 for all future horizons, rather than revert back to its mean

我们可以用 GARCH Model 解决上面的 limitation

$$\sigma_{ij,t+1} = \omega_{ij} + \alpha R_{i,t} R_{j,t} + \beta \sigma_{ij,t}$$

$$\sigma_{ij} = \omega_{ij} / (1 - \alpha - \beta)$$

但是这样的模型也是有其局限性的

α, β 没有下标 \rightarrow same for every pair of stocks

为什么要这样呢？确保了 covariance matrix 是半正定的。variance of portfolio > 0

之前的模型 (equally-weighted / exponential-weighted) 都没有这个问题

我们进行的这个假设 (α, β 都一样) 是很强的限制条件，不太现实

所以我们怎么办呢？我们直接为 correlation 建模： (DCC model)

$$\rho_{ij,t+1} = \sigma_{ij,t+1} / (\sigma_{ii,t+1} \sigma_{jj,t+1})$$

thus 我们用 { GARCH 算出来的方差 进行组合，得到 covariance matrix
DCC 算出来的 ρ

$$\Sigma_{t+1} = D_{t+1} \Gamma_{t+1} D_{t+1}$$

$$\begin{bmatrix} \rho_{11} & \\ \vdots & \ddots \\ \rho_{n1} & \end{bmatrix} \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1n} \\ \rho_{21} & 1 & \dots & \rho_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{n1} & \rho_{n2} & \dots & 1 \end{bmatrix} \begin{bmatrix} \sigma_{11} & \\ \vdots & \ddots \\ \sigma_{nn} & \end{bmatrix}$$

那么 Γ 怎么求呢？

$$z_{i,t+1} = \frac{R_{i,t+1}}{\sigma_{i,t+1}}$$

$$E(z_{i,t+1} z_{j,t+1}) = \rho_{ij,t+1} \quad \text{for all } i, j$$

\hookrightarrow 它们的 covariance 就是 correlation

那么我们如何估计 $E(z_{i,t+1} z_{j,t+1})$ 呢？我们引入中间量 q

$$q_{ij,t+1} = \rho_{ij} + \alpha (z_{i,t} z_{j,t} - \rho_{ij}) + \beta (q_{ij,t} - \rho_{ij})$$

q 几乎是 correlation. 但它的范围有问题 ($|q|$ 可能 > 1). 需要 rescale

$$\rho_{ij,t+1} = \frac{q_{ij,t+1}}{\sqrt{q_{ii,t+1} q_{jj,t+1}}}$$


这是 DCC (1, 1) Model

注意这里的 α 和 β 还是一样的. 但是 $\rho_{i,j}$ 不一样

\rightarrow does imply the persistence in correlation is constant across assets

correlation 就是随机变化的

DCC correlation between
S & P 500 and 10-Year Treasury
note :



上面的模型参数的系数太多了，那我们怎么办呢？

$$\bar{\rho}_{ij} = \frac{1}{T} \sum_{t=1}^T z_{i,t} z_{j,t}$$

$$q_{ij,t+1} = \bar{\rho}_{ij} + \alpha (z_{i,t} z_{j,t} - \bar{\rho}_{ij}) + \beta (q_{ij,t} - \bar{\rho}_{ij})$$

只有两个系数

III Estimation

下面介绍如何估计 DCC 模型的系数：

尽管我们直觉上想用 MLE，但是 MLE 是不成的

We will take two shortcuts

- The first shortcut is to do the estimation sequentially
 - First estimate a set of GARCH models for variances 用 GARCH 行估计
 - Compute normalized returns $\rightarrow z_1 / z_2$
 - Estimate the DCC model on the normalized returns
- The second shortcut is the replace the log-likelihood with a composite likelihood formed from bivariate log likelihoods
用新方法重新估计

我们先看：MLF有什么问题：

假设 returns 是 conditionally normally distributed
(当然别的分布也可以)

用MLF需要估计 DCC 的 α 和 β ，每一个 asset 的 α_i , β_i , σ_{ii} , δ_{ii} 。
要估太多系数了！:(

The conditional density of r_{t+1} is

$$f(r_{t+1}) = \frac{1}{\sqrt{(2\pi)^k |\Sigma_{t+1}(\theta)|}} \exp \left[-\frac{1}{2} r'_{t+1} (\Sigma_{t+1}^{-1}(\theta)) r_{t+1} \right]$$

The log likelihood is obtained by taking the log and summing over the observations

Here $\Sigma_{t+1}^{-1}(\theta)$ is a highly nonlinear function of the parameters, and when n is large matrix inversion is slow

In addition, $\Sigma_{t+1}(\theta)$ is often close to singular (stock returns tend to be highly correlated), making the situation worse → 接近不可逆

Maximization of the log likelihood of the DCC model is a challenging problem 都碰壁了还求丁捷径！

所以我们怎么办呢？我们走西丁捷径：

西丁捷径： sequentially

一步一步算。先把 GARCH 都搞出来。再算 $z_{i,t+1} = \frac{r_{i,t+1}}{\sigma_{i,t+1}}$

现在 MLF 只有两个系数了：DCC 的 α 和 β

但 ppt 里的 正定矩阵问题还是有的：

The conditional density of the vector z_{t+1} is

$$f(z_{t+1}) = \frac{1}{\sqrt{(2\pi)^k |\Upsilon_{t+1}(\alpha, \beta)|}} \exp \left[-\frac{1}{2} z'_{t+1} (\Upsilon_{t+1}^{-1}(\alpha, \beta)) z_{t+1} \right]$$

Remember that Υ_{t+1} is the correlation matrix

The log likelihood is again obtained by taking the log and summing over the observations

- Now there are only two parameters, α and β
- $\Upsilon_{t+1}^{-1}(\alpha, \beta)$ is still a highly nonlinear function of the parameters, and when n is large matrix inversion is slow
- In addition, $\Upsilon_{t+1}(\alpha, \beta)$ is often close to singular (stock returns tend to be highly correlated), making the situation worse
- Maximization of the log likelihood is a less challenging numerical problem than before, but still can be a problem

第二十讲：Composite likelihood

我们把 n 维的矩阵换成 $z_{i,t+1}$ 和 $z_{j,t+1}$ 的 joint density

$$f(z_{i,t+1}, z_{j,t+1}) = \frac{1}{2\pi\sqrt{1-\rho_{ij,t+1}^2}} \exp\left[-\frac{1}{2} \frac{z_{i,t+1}^2 - 2\rho_{ij,t+1}z_{i,t+1}z_{j,t+1} + z_{j,t+1}^2}{1-\rho_{ij,t+1}^2}\right]$$

$$\rho_{ij,t} = \frac{q_{ij,t}}{\sqrt{q_{ii,t}q_{jj,t}}}$$

where

$$q_{ii,t+1} = 1 + \alpha(z_{i,t}^2 - 1) + \beta(q_{ii,t} - 1)$$

$$q_{ij,t+1} = \bar{\rho}_{ij} + \alpha(z_{i,t}z_{j,t}^2 - \bar{\rho}_{ij}) + \beta(q_{ij,t} - \bar{\rho}_{ij})$$

$$q_{jj,t+1} = 1 + \alpha(z_{j,t}^2 - 1) + \beta(q_{jj,t} - 1)$$

$$q_{ii,t+1} = 1 \quad q_{ii,t+1} = 1 \quad q_{ij,t+1} = \bar{\rho}_{ij} \quad \bar{\rho}_{ij} = \frac{1}{T} \sum_{t=1}^T z_{i,t} z_{j,t}$$

$$\ln(CL_c) = -\frac{1}{2} \sum_{t=1}^T \sum_{i=1}^n \sum_{j>i} \left(\ln(1 - \rho_{ij,t}^2) + \frac{(z_{i,t}^2 + z_{j,t}^2 - 2\rho_{ij,t}z_{i,t}z_{j,t})}{(1 - \rho_{ij,t}^2)} \right)$$

接下来讲 - T Generalization: Asymmetric correlation model

$$Q_{t+1} = (1 - \alpha - \beta) E[z_t z_t'] + \alpha (z_t z_t') + \beta Q_t + \gamma (\eta_t \eta_t' - E[\eta_t \eta_t'])$$

where the $\eta_{i,t}$ for asset i is defined as the negative part of $z_{i,t}$ as follows:

$$\eta_{i,t} = \begin{cases} z_{i,t}, & \text{if } z_{i,t} < 0 \\ 0, & \text{if } z_{i,t} \geq 0 \end{cases} \quad \text{for all } i$$

Note that $E[\eta_t \eta_t']$ is a matrix; it can be estimated as the sample average of $\eta_t \eta_t'$.

Similarly, $E[z_t z_t']$ can be estimated as the sample average of $z_t z_t'$.

correlation tends to be higher in down markets