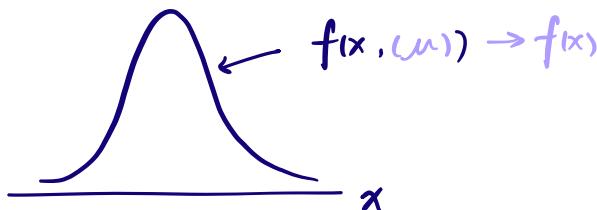


# Maximum Likelihood Estimation

main idea :

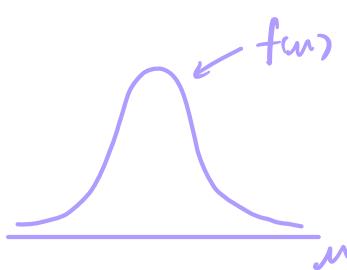
$$1 \text{ observation } f(x, \mu) = \frac{1}{\sqrt{2\pi} \times b} \times \exp \left\{ -\frac{1}{2} \left( \frac{x-\mu}{b} \right)^2 \right\}$$



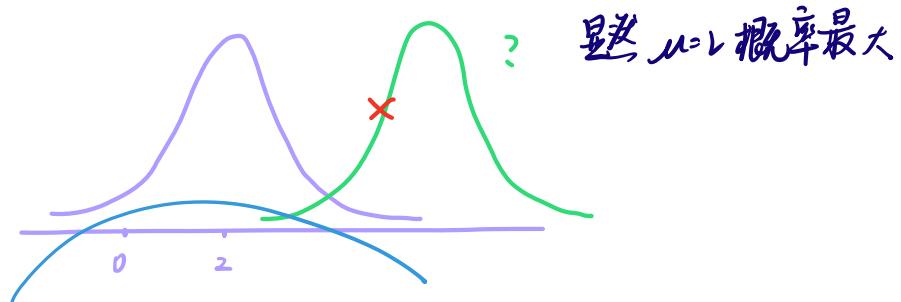
only one parameter

我们现在想用  $x$  来估计  $\mu$

↓



我们看到  $x=2$ , 那么  $\mu=12$ ? → 不是好的 estimate



用 lnf 比较好. for two reasons

Theoretical Reason

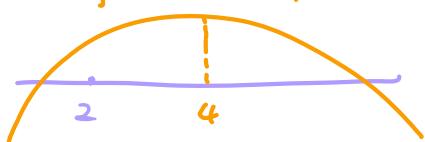
practical reason : s.d. 如果特别小

会有 floating point overflow problems

以及, 我们现在只有一 T observation. 如果有很多 observations 怎么办? 需要算 joint distribution. 即要把 density 乘起来 (if independent)  $\ln ab = \ln a + \ln b$ . 这很好

假如我们有两 T observation :

$$\ln f(x_1, \mu=4)$$



$$\ln f(x_2, \mu=4)$$



其值不应该呈 4, 而是  $\frac{2+5.37}{2}$

我们需要找一个 simple parameter factor maximize the sum of components  
看起来不好找，但实际上很简单，求导就可以了

把  $\ln f$  加起来，找到最大值

$$f(x_3, x_2, x_1, \mu, \sigma) = f(x_3) f(x_2) f(x_1) \quad (\text{If independent})$$

If not independent:  $f(x_3 | x_1, x_2) f(x_2 | x_1) f(x_1)$  → conditional density

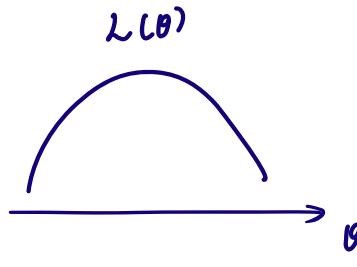
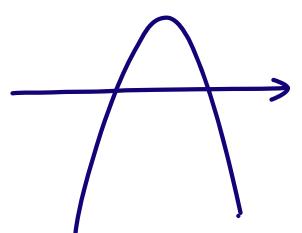
financial model 一般告诉你的 conditional density 是什么

$$x_2 = \alpha + \beta x_1 + \varepsilon_2, \quad \varepsilon_2 \sim N(0, \sigma^2)$$

$$\frac{1}{\sqrt{2\pi} \cdot \sigma} \exp \left\{ -\frac{1}{2} \frac{[x_2 - (\alpha + \beta x_1)]^2}{\sigma^2} \right\}$$

• log likelihood

one unknown parameter  $\theta$



x

o

We care about curvature

# GARCH Modeling

- GARCH — Generalized Autoregressive Conditional Heteroscedasticity
  - 用于预测 volatility (different variances)
- It's conditional because it depends on some past data
- $\delta_{t+1}^2 = \omega + \alpha R_t^2 + \beta \delta_t^2$ ,  $\alpha + \beta < 1$  — GARCH(1,1)

GARCH Model 有什么用呢？

- Mean - Variance optimization
  - 需要 mean (假设已知), covariance matrix (s.d. → 本课内容, correlation)
- Delta-normal & Monte Carlo VaR
  - 也用到了 covariance matrix
- Filtered Historical Simulation
  - 需要 rescaled returns  $\frac{\delta_{t+1}}{\delta_t} \times R_t$ .  $\delta_{t+1}$  和  $\delta_t$  可用 GARCH 模型
  - 为什么要用 GARCH 模型呢？

假如我们有 database of returns. Naive historical simulation 的一个局限就是一些数据是五年前的，那时 volatility 更低  $\rightarrow$  not so relevant

$$\begin{bmatrix} R_{t-\tau} & \delta_{t+1} \\ \delta_{t-\tau} & \end{bmatrix} \rightarrow \text{var} = \delta_{t+1}^2 \Rightarrow \text{这样我们就能用所有的数据了}$$

- 假如 implied volatility 没有的话，可以用 GARCH 的 volatility 来定价

如果有 implied volatility 那就一定用 implied volatility，但有些国家就没有健全的期权机制

- 我们从 Simple Variance Forecasting 说起

$$R_{t+1} \equiv \ln\left(\frac{s_{t+1}}{s_t}\right)$$

$$\begin{aligned} R_{t+1} &= \delta_{t+1} z_{t+1}, \quad z_{t+1} \sim i.i.d. N(0,1) \\ \Rightarrow \delta_{t+1}^2 &= \sum_{i=1}^m \frac{1}{m} R_{t+1-i}^2 \end{aligned}$$

- Risk Metrics

$$\hat{\sigma}_{t+1}^2 = \lambda \hat{\sigma}_t^2 + (1-\lambda) R_t^2 \rightarrow \text{这就和 GARCH 很像}$$

↓

GARCH Model, 看起来很灵活

$$\hat{\sigma}_{t+1}^2 = w + \alpha R_t^2 + \beta \hat{\sigma}_t^2, \text{ with } \alpha + \beta < 1$$

$\Rightarrow$  GARCH (1, 1)

one lag of the return  $\downarrow$  one lag of the conditional variance  $\hat{\sigma}_t^2$

$$\delta^2 \equiv E[\hat{\sigma}_{t+1}^2] = w + \alpha E[R_t^2] + \beta E[\hat{\sigma}_t^2]$$

$$= w + \alpha \delta^2 + \beta \delta^2$$

$$\Rightarrow \delta^2 = \frac{w}{1-\alpha-\beta} \quad \text{It's stationary}$$

$$\Rightarrow w = (1-\alpha-\beta) \delta^2$$

$$\hat{\sigma}_{t+1}^2 = (1-\alpha-\beta) \delta^2 + \alpha R_t^2 + \beta \hat{\sigma}_t^2 = \underline{\delta^2} + \alpha \underline{(R_t^2 - \delta^2)} + \beta \underline{(\hat{\sigma}_t^2 - \delta^2)}$$

thus 看作是 weighted average of “-”

$\delta$

t            t+1        ...            t+k-1        t+k

取数据之前  $\leftarrow \hat{\sigma}_t^2 \xrightarrow{\text{决定}} \hat{\sigma}_{t+1}^2 \xrightarrow{\text{...}} \cdots \xrightarrow{\hat{\sigma}_{t+k-1}^2 \xrightarrow{\text{决定}} \hat{\sigma}_{t+k}^2}$   
的数据

$$w + \alpha R_t^2 + \beta \hat{\sigma}_t^2$$

下面是很漂亮的数学：

$$\begin{aligned}
 E_t[\delta_{t+k}^2] - \sigma^2 &= \alpha E_t[R_{t+k-1}^2 - \sigma^2] + \beta E_t[\delta_{t+k-1}^2 - \sigma^2] \\
 &= \alpha E_t[\delta_{t+k-1}^2 Z_{t+k-1}^2 - \sigma^2] + \beta E_t[\delta_{t+k-1}^2 - \sigma^2] \\
 &= (\alpha + \beta) \underbrace{E_t[\delta_{t+k-1}^2]}_{\sigma^2} - \sigma^2
 \end{aligned}$$

很容易找到通项公式

$$E_t[\delta_{t+k}^2] - \sigma^2 = (\alpha + \beta)^{k-1} (\delta_{t+1}^2 - \sigma^2)$$

$\rightarrow$  standard deviation per day

注意 Returns are uncorrelated. 但不是 independent

\*  $\alpha + \beta < 1$ , variance will be mean-reverting  $\rightarrow$  stationary

但时常  $\alpha + \beta = 0.99 / 0.98$

但是 GARCH model 的一些 parameters 需要 MLE

data	variance	conditional density	$\rightarrow$ log conditional density function
$r_1$	$\delta_1^2$	$\frac{1}{\sqrt{2\pi}} \frac{1}{\delta_2^2(\delta_1^2, w, \alpha, \beta)} \cdot \exp\left(-\frac{1}{2} \frac{r_1^2}{\delta_2^2(\delta_1^2, w, \alpha, \beta)}\right)$	
$r_2$	$w + \alpha r_1^2 + \beta \delta_1^2$	$\downarrow$	and add them up
$r_3$	$w + \alpha r_2^2 + \beta \delta_2^2$	$\delta_2^2 = w + \alpha r_1^2 + \beta \delta_1^2$	

$\downarrow$

for each observation we can  
write the variance

# GARCH Modeling

$$E_t [\sigma_{t+k}^2] - \sigma^2 = (\alpha + \beta)^{k-1} (\sigma_{t+1}^2 - \sigma^2) \rightarrow \text{use for forecasting}$$

在 GPD 中我们做了什么？我们得到了所有 observation 的 density . GARCH 也是一样的

- 现在我们假设 return 是符合正态分布的：

$$R_t = \sigma_t z_t, \quad z_t \sim \text{i.i.d. } N(0, 1)$$

Probability of  $R_t$  is

$$l_t = \frac{1}{\sqrt{2\pi}\sigma_t} \exp\left(-\frac{R_t^2}{2\sigma_t^2}\right)$$

那么 joint likelihood 就是

$$L = \prod_{t=1}^T l_t = \prod_{t=1}^T \frac{1}{\sqrt{2\pi}\sigma_t} \exp\left(-\frac{R_t^2}{2\sigma_t^2}\right)$$

注意：我们这里把 likelihood 乘起来并不意味着 return 是相互独立的

$$\sigma_t^2 = \sigma^2(1-\alpha-\beta) + \alpha R_{t-1}^2 + \beta \sigma_{t-1}^2$$

在用 MLE 时，我们会 maximize  $\sigma^2, \alpha, \beta$

$$= w + \alpha R_{t-1}^2 + \beta \sigma_{t-1}^2$$

这时候就是 maximize  $w, \alpha, \beta$

$$\text{Max } \ln L = \text{Max} \sum_{t=1}^T \ln(l_t) = \text{Max} \sum_{t=1}^T \left[ -\frac{1}{2} \ln(2\pi) - \frac{1}{2} \ln(\sigma_t^2) - \frac{1}{2} \frac{R_t^2}{\sigma_t^2} \right]$$

$$\text{可以看作 maximize } \left[ -\frac{1}{2} \left( \sum_{t=1}^T \ln \sigma_t^2 + \frac{\bar{R}_T^2}{\bar{\sigma}_T^2} \right) \right]$$

MLE 是很好的，随着 sample size  $T \rightarrow \infty$ , parameter estimates  $\rightarrow$  true values  
estimates 的方差也最小

注意！就算 conditional distribution is not normal, MLE 的 estimate 还是会收敛于真实值

我们在做 MLE 时，需要用到第四 T parameter：

$$\delta_1^2 = \omega + \alpha R_0^2 + \beta \delta_0^2$$

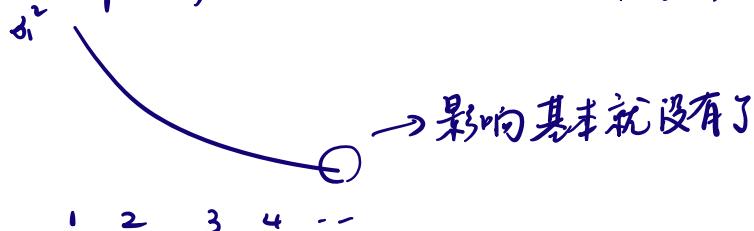
— 假如我们的数据是从  $t=1$  开始的， $R_0$  和  $\delta_0$  根本不存在，那该怎么办呢？  
我们就需要引入  $\delta_1^2$

$\delta_1$  是哪来的呢？  $\delta_1 = \frac{1}{\sqrt{2\pi\delta_1^2}} \exp\left(-\frac{R_1^2}{2\delta_1^2}\right)$

用 MLE 估计 T parameter 就可以了

而 long-run variance 可以看作 sample variance

$\hat{\delta}_1^2 = \frac{1}{N} \sum_{t=1}^N R_t^2 \rightarrow$  用 sample variance 估计，但其实是错的，而很多人是这样做的。 $\delta_1^2$  其实不影响后来的方差

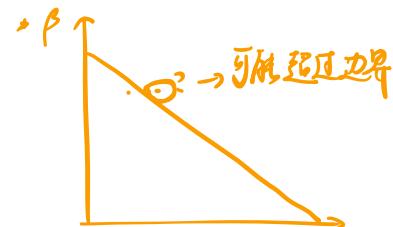
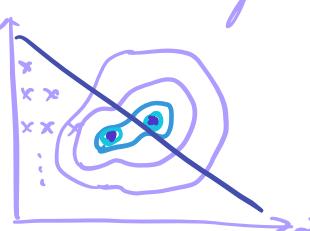


\* 注意！Optimizer 是需要我们猜值的，在 Bloomberg 中是不能乱猜的。

因为只估计  $\alpha$  和  $\beta$ ，不需要 optimizer

我们要施加限制条件

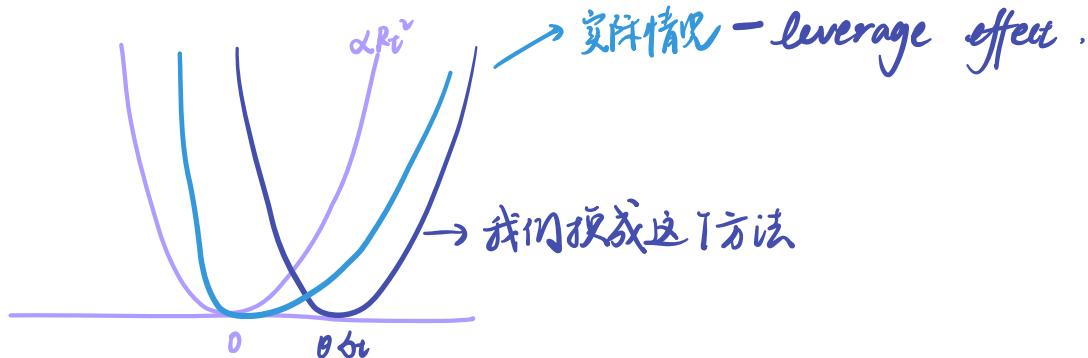
$\alpha, \beta \geq 0$ , 因为  $\alpha$  不能 < 0,  $\alpha + \beta < 1$



# More on GARCH Modeling

- 之前我们一直在用 GARCH(1,1). 它有什么问题呢?

It's SYMMETRIC :  $\delta_{t+1}^2 = \omega + \alpha R_t^2 + \beta \delta_t^2$



实际情况有什么特征呢?  $\alpha R_t^2$  is symmetric around 0

Return 同样变化 5%, -5% 带来的 variance 增长比 5% 带来的 variance 增长大  $\Rightarrow$  这叫做 leverage effect 为了捕捉这一特征, 我们引入  $\theta$

$$\delta_{t+1}^2 = \omega + \alpha (R_t - \theta \delta_t)^2 + \beta \delta_t^2 = \omega + \alpha \delta_t^2 (z_t - \theta)^2 + \beta \delta_t^2 \rightarrow NGARCH \text{ model}$$

capture the asymmetry

这是 first approach  $\rightarrow$  和 GARCH(1,1) 一样简单

\*  $E[\delta_{t+1}^2] = \omega + (\alpha(1+\theta^2) + \beta) E[\delta_t^2]$

\* 为什么叫做 leverage effect?

当 stock price  $\downarrow$ , companies are more leveraged

A more natural way to do is to introduce a dummy variable  $I$   
allows the slope to be different to the right and left of 0.

这样 Model 就变成了  $\delta_{t+1}^2 = \omega + \alpha R_t^2 + \alpha \theta I_t R_t^2 + \beta \delta_t^2$

上面的这些方法都有较强的操作性，为什么呢？

$$\frac{1}{\sqrt{2\pi}} \cdot \frac{1}{\delta t} \cdot \exp \left\{ -\frac{1}{2} \frac{\hat{R}_t^2}{\delta t^2} \right\}$$

→ 有的可能不是 stationary  
对于 almost any function 来说，它都是 stationary 的  
只是 specification 不一样

④ 捕捉了 leveraged effect — GJR-GARCH model.

接下来我们放宽条件， $\alpha, \beta$  不一定  $> 0 \rightarrow \ln \delta_{t+1}^2, \bar{s}_{t+1} < 0$

$$\ln \delta_{t+1}^2 = \omega + \alpha (\phi R_t + \gamma [1_{R_t=1} - E[1_{R_t=1}]] + \rho \ln \delta_t^2)$$

$\alpha \phi < 0 \rightarrow$  leverage effect

当然我们也可以取更多的 lag : GARCH(p,q)

$$\delta_{t+1}^2 = \omega + \sum_{i=1}^p \alpha_i R_{t+1-i}^2 + \sum_{j=1}^q \beta_j \delta_{t+1-j}^2 \text{ 但一般取 lag } = 2$$

estimation is annoying. 昨天的 variance 和今天的 variance 有很强的相关性，我们也很难解释

让我们回到 GARCH(1,1) model 中来 可能 long-run variance 是随机过程

\* 右侧可以加任意 Explanatory variables. 比如  $\bar{s}_{t+1}$  - Calendar Effect 的 dummy variable, 比如 是否是周一, 是否在 Dec 15 ~ Jan 1 之间

→这就涉及到了 Model Selection 的问题：选哪个 Model 呢？

举一例：

$$GARCH(1,1) = \alpha + \beta \cdot \sigma^2 + \delta_1^2 \quad \theta=0 \quad \ln L_0$$

$$NGARCH(1,1) = \alpha + \beta \cdot \sigma^2 + \delta_1^2 + \theta \quad \ln L_1$$

$\ln L_1$  更大，因为在 GARCH(1,1) 有  $\theta=0$ ，unrestricted 一定大于等于 restricted 的 log likelihood

$$\text{它们的差值 } 2(\ln L_1 - \ln L_0) \sim \chi^2_{df} = LR$$

$$df = \# \text{ of constraints}$$

under the  $H_0$ : added parameters in model 1 are significant

如果  $LR$  is large ( $> \chi^2$  critical value, 我们就应该选择更加灵活的 model)

有什么 Limitation 呢？ Always reject the less flexible model

为什么呢？ mean return 的 confidence interval 是很大的， so volatile that doesn't contain too much information.

我们不知道 CAPM, FF-3 factor model 是否准确 Average return 不能用来预测 expected return

而对于 variation 来说，data is so informative，模型会永远选择包括更多 parameter 的模型

那我们怎么办呢？ ad hoc thing。如果你有一 T 的模型 (good variance forecast)， $R_{t+1}^2 = b_0 + b_1 \delta_{t+1}^2 + \epsilon_{t+1}$ 。  $b_0=0$ ， $b_1=1$

我们需要针对具体数据具体分析